# 一元线性最小二乘拟合的理论推导

给定一组平面上的观测点，我们希望找到一条直线，使它能够概括数据的主要变化趋势。由于测量误差或模型近似，观测点通常不会全部落在同一条直线上。因此，问题并不是让直线逐点通过所有数据，而是先定义一个整体误差，再寻找使误差最小的斜率与截距。

本文从残差平方和出发，依次推导最优参数、唯一性条件和矩阵表达，并用四个数据点核对结果。除最后的正则化扩展外，全部讨论都针对带截距的一元线性模型；优化过程不要求误差服从某种概率分布。

## 1 问题定义 Problem Formulation

设共有 $n$ 组观测数据 $(x_i, y_i)$，其中 $i = 1, 2, \dots, n$。我们使用斜率为 $a$、截距为 $b$ 的直线表示预测值：

$$\hat{y}_i = a x_i + b.$$

观测值减去预测值得到残差。残差为正，表示直线在该点低估了观测值；残差为负，则表示直线高估了观测值。对任意待选参数，记

$$e_i(a, b) = y_i - a x_i - b.$$

如果直接求残差之和，正负误差可能互相抵消。最小二乘法因此使用残差的平方和作为目标函数：

$$J(a, b) = \sum_{i=1}^{n} (y_i - a x_i - b)^2, \qquad (\hat{a}, \hat{b}) = \arg\min_{a,b} J(a, b).$$

这里采用的是沿 $y$ 方向的误差，并非点到直线的最短几何距离。目标函数除以 $n$ 会得到均方误差；由于这只是乘上一个正常数，最优参数保持不变。

## 2 由一阶条件得到正规方程 Normal Equations

目标函数是关于 $a$ 和 $b$ 的二次多项式。若最小值在某一参数对处取得，则该处两个偏导数都必须为零。分别求导可得

$$\frac{\partial J}{\partial a} = -2 \sum_{i=1}^{n} x_i (y_i - a x_i - b),$$
$$\frac{\partial J}{\partial b} = -2 \sum_{i=1}^{n} (y_i - a x_i - b).$$

令这两个表达式同时为零，并将包含未知参数的项移到等号左侧，就得到一个关于斜率和截距的线性方程组：

$$\begin{cases} a\sum_{i=1}^{n} x_i^2 + b\sum_{i=1}^{n} x_i = \sum_{i=1}^{n} x_i y_i, \\ a\sum_{i=1}^{n} x_i + nb = \sum_{i=1}^{n} y_i. \end{cases}$$

这就是本问题的正规方程。虽然原始目标是最小化一个函数，但求解过程已经化为两个线性方程。接下来将它改写为中心化形式，可以使参数的含义和退化条件更加清楚。

# 3 中心化与参数的显式解 Centered Solution

## 3.1 先消去截距

定义观测量的算术平均值：

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i, \qquad \bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i.$$

正规方程的第二式除以 $n$ 后，给出 $b = \bar{y} - a\bar{x}$。这说明：对每一个固定的斜率，最优截距都使直线通过样本中心 $(\bar{x}, \bar{y})$。把这一关系代回残差，有

$$y_i - ax_i - b = (y_i - \bar{y}) - a(x_i - \bar{x}).$$

中心化后的变量满足 $\sum_i (x_i - \bar{x}) = 0$ 和 $\sum_i (y_i - \bar{y}) = 0$。它们把整体位置与相对变化分离开来，使后续推导只需要关注数据在中心周围的分布。

## 3.2 展开为一元二次函数

为简化记号，定义三个中心化求和量：

$$\begin{aligned} S_{xx} &= \sum_{i=1}^{n} (x_i - \bar{x})^2, \\ S_{xy} &= \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}), \\ S_{yy} &= \sum_{i=1}^{n} (y_i - \bar{y})^2. \end{aligned}$$

沿着最优截距的关系消去 $b$，再将平方项展开，目标函数可以写成

$$\begin{aligned} J_c(a) &\equiv J(a, \bar{y} - a\bar{x}) \\ &= \sum_{i=1}^{n} \left[ (y_i - \bar{y}) - a(x_i - \bar{x}) \right]^2 \\ &= S_{yy} - 2aS_{xy} + a^2 S_{xx}. \end{aligned}$$

当 $S_{xx} > 0$ 时，对 $a$ 求导并令结果为零，便得到最优斜率。随后恢复截距：

$$\frac{\mathrm{d}J_c}{\mathrm{d}a} = -2S_{xy} + 2aS_{xx} = 0, \qquad \boxed{\hat{a} = \frac{S_{xy}}{S_{xx}}, \quad \hat{b} = \bar{y} - \hat{a}\bar{x}}.$$

分子 $S_{xy}$ 描述两组数据在中心周围共同变化的方向，分母 $S_{xx}$ 描述自变量的离散程度。两者的比值将共同变化的量转化为单位自变量变化所对应的预测变化。

# 4 为什么这是唯一的最小值 Uniqueness

仅有偏导数为零，还不足以在一般问题中证明取得最小值。这里可以直接对二次函数配方。将刚才求出的 $\hat{a}$ 代入，有

$$J_c(a) = S_{xx}(a - \hat{a})^2 + S_{yy} - \frac{S_{xy}^2}{S_{xx}}.$$

当 $S_{xx} > 0$ 时，第一项非负，并且只有在 $a = \hat{a}$ 时为零。因此斜率唯一；对每个斜率而言，截距也由均值关系唯一确定。最小残差平方和为

$$J_{\min} = S_{yy} - \frac{S_{xy}^2}{S_{xx}} \geq 0.$$

也可以从两个变量的 Hessian 矩阵检查这一点。它的表达式及行列式为

$$H = 2\begin{pmatrix} \sum_i x_i^2 & \sum_i x_i \\ \sum_i x_i & n \end{pmatrix}, \qquad \det H = 4nS_{xx}.$$

当至少有两个不同的 $x_i$ 时，$S_{xx} > 0$，上述对称矩阵正定，所以目标函数严格凸，驻点就是唯一的全局最小值。

## 4.1 自变量完全相同时会怎样

如果所有 $x_i$ 都等于同一个常数 $c$，则 $S_{xx} = 0$。此时每个预测值都是 $ac + b$，数据只能确定这个组合，不能分别确定斜率和截距。全部最优参数满足

$$ac + b = \bar{y}.$$

因此，斜率公式中的零分母不是计算上的偶然异常，而是模型缺少可辨识信息的表现。需要改变数据的自变量取值，或对参数加入额外约束，才能进一步确定解。

# 5 矩阵形式与残差正交 Matrix Form

把观测值、参数和自变量整理成向量与矩阵：

$$\boldsymbol{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}, \quad \boldsymbol{\theta} = \begin{pmatrix} a \\ b \end{pmatrix}, \quad X = \begin{pmatrix} x_1 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{pmatrix}.$$

目标函数变为 $J(\boldsymbol{\theta}) = \|\boldsymbol{y} - X\boldsymbol{\theta}\|_2^2$。对参数向量求梯度，得到与前面完全相同的正规方程：

$$\nabla_{\boldsymbol{\theta}} J = 2X^{\mathrm{T}}(X\boldsymbol{\theta} - \boldsymbol{y}) = \mathbf{0}, \qquad X^{\mathrm{T}}X\hat{\boldsymbol{\theta}} = X^{\mathrm{T}}\boldsymbol{y}.$$

若 $X$ 的两列线性无关，则 $X^{\mathrm{T}}X$ 可逆，参数可以形式化地写为

$$\hat{\boldsymbol{\theta}} = (X^{\mathrm{T}}X)^{-1}X^{\mathrm{T}}\boldsymbol{y}.$$

定义最优残差向量 $\boldsymbol{r} = \boldsymbol{y} - X\hat{\boldsymbol{\theta}}$，正规方程随即给出

$$X^{\mathrm{T}}\boldsymbol{r} = \mathbf{0} \quad \Longleftrightarrow \quad \sum_{i=1}^{n} r_i = 0, \qquad \sum_{i=1}^{n} x_i r_i = 0.$$

这意味着最优残差与模型能够表达的两个方向正交：一个方向对应常数项，另一个对应自变量。几何上，预测向量是观测向量在 $X$ 的列空间上的正交投影；继续沿模型允许的方向移动参数，都不能进一步减小残差平方和。

## 6 一个可以手算的例子 Worked Example

考虑下表中的四个观测点。先通过数据求参数，再检查残差的两个正交条件。

| 序号 $i$ | $x_i$ | $y_i$ | $\hat{y}_i$ | $r_i$ |
|---|---|---|---|---|
| 1 | 0 | 1 | 0.9 | 0.1 |
| 2 | 1 | 2 | 1.8 | 0.2 |
| 3 | 2 | 2 | 2.7 | −0.7 |
| 4 | 3 | 4 | 3.6 | 0.4 |

由原始数据得到 $\bar{x} = 1.5$、$\bar{y} = 2.25$，以及

$$S_{xx} = 5, \qquad S_{xy} = 4.5, \qquad S_{yy} = 4.75.$$

于是 $\hat{a} = 4.5/5 = 0.9$，$\hat{b} = 2.25 - 0.9 \times 1.5 = 0.9$。拟合直线和最小残差平方和分别为

$$\boxed{\hat{y} = 0.9x + 0.9}, \qquad J_{\min} = 4.75 - \frac{4.5^2}{5} = 0.70.$$

表中的残差还满足下面两式。它们可以作为推导结果和数值计算结果的独立核对：

$$\sum_{i} r_i = 0.1 + 0.2 - 0.7 + 0.4 = 0,$$
$$\sum_{i} x_i r_i = 0 \times 0.1 + 1 \times 0.2 + 2 \times (-0.7) + 3 \times 0.4 = 0.$$

残差之和为零不表示拟合没有误差。这个例子的残差平方和仍然为 0.70，只不过正负残差在求和时恰好抵消；这也再次解释了为什么需要平方和作为优化目标。

## 7 一个简单扩展：斜率正则化 Regularization

如果希望限制斜率的绝对大小，可以在原目标中加入二次惩罚项。只惩罚斜率、不惩罚截距时，定义

$$J_\lambda(a,b)=\sum_{i=1}^{n}(y_i-ax_i-b)^2+\lambda a^2,\qquad \lambda>0.$$

由于新增项与 $b$ 无关，最优截距仍满足均值关系。消去截距后，再对斜率求导，得到

$$J_{\lambda,c}(a)=S_{yy}-2aS_{xy}+(S_{xx}+\lambda)a^2,\qquad \hat{a}_\lambda=\frac{S_{xy}}{S_{xx}+\lambda}.$$

截距为 $\hat{b}_\lambda=\bar{y}-\hat{a}_\lambda\bar{x}$。当 $S_{xx}>0$ 时，可以把新斜率写为原斜率乘以一个小于一的系数：

$$\hat{a}_\lambda=\frac{S_{xx}}{S_{xx}+\lambda}\hat{a},\qquad \lim_{\lambda\to\infty}\hat{a}_\lambda=0,\qquad \lim_{\lambda\to\infty}\hat{b}_\lambda=\bar{y}.$$

惩罚越强，预测直线越接近只输出样本均值的水平线。在前面的例子中，若取 $\lambda=1$，则斜率变为 $4.5/6=0.75$，截距变为 $1.125$。正则化改变了优化目标，因此不应要求它继续取得原始残差平方和的最小值。

## 8 推导的适用条件与计算检查

1. **检查数据是否足以确定参数**：带截距的直线拟合至少需要两个不同的自变量取值，才能得到唯一的普通最小二乘解。
2. **检查误差的定义**：本文最小化纵向残差平方和；若两个坐标都存在需要建模的误差，问题的定义也需要相应调整。
3. **检查数值计算结果**：无正则化时，残差应近似满足 $\sum_i r_i=0$ 和 $\sum_i x_i r_i=0$，允许存在浮点舍入误差。

本文中的显式逆矩阵用于说明理论关系。实际编程时可以直接求解线性系统；更一般的最小二乘问题通常使用 QR 或 SVD 分解，避免把显式求逆当作默认实现步骤。无论采用何种数值方法，中心化公式、唯一性条件和残差正交关系都提供了理解与检查结果的依据。